

MMD GANs

Mahdi Bouafif Rayene Tahar Nour Ghamgui
Mohamed Boudouh

Télécom Paris — Institut Polytechnique de Paris

Encadrant: Arthur Leclaire

Juin 2026



Outline

- 1 Contexte: GAN et MMD-GAN
- 2 Résultats sur MNIST
- 3 Résultats sur CelebA
- 4 Exploration (Exploitation) de l'espace latent du bruit

Generative Adversarial Networks

Principe

Introduits par Goodfellow et al. (2014), les GANs reposent sur une idée simple et élégante : apprendre à générer des données réalistes en faisant s'affronter deux réseaux de neurones dans un jeu compétitif l'un cherche à **tromper**, l'autre à **détecter**.

Ce jeu s'écrit comme un problème min-max :

$$\min_{\psi} \max_{\theta} \mathbb{E}_{x \sim P} [\log D_{\theta}(x)] + \mathbb{E}_z [\log(1 - D_{\theta}(G_{\psi}(z)))]$$

Limitations

- **Saturation des gradients** : si D_{θ} est trop performant, le signal vers G_{ψ} disparaît
- **Mode collapse** : le générateur ignore certains modes de la distribution cible
- **Instabilité** : l'entraînement oscille et diverge facilement

Des GANs aux IPM

Pourquoi remplacer Jensen-Shannon ?

Il a été montré que le problème min-max présenté précédemment est équivalent à minimiser la **divergence de Jensen-Shannon** entre P et Q_ψ , surtout qu'elle devient **constante et non informative** dès que les supports de P et Q_ψ ne se chevauchent pas ce qui est précisément le cas en début d'entraînement.

Integral Probability Metrics (IPM)

Une famille de métriques plus adaptées : les **métriques à probabilité intégrale**. Leur avantage clé : elles restent **informatives et fournissent un gradient utile** même quand les supports ne se chevauchent pas.

$$\mathcal{D}_{\mathcal{F}}(P, Q) = \sup_{f \in \mathcal{F}} [\mathbb{E}_{x \sim P}[f(x)] - \mathbb{E}_{y \sim Q}[f(y)]]$$

MMD GAN

Intuition

Au lieu d'avoir un discriminateur qui classe chaque image une par une en "vrai" ou "faux", la **Maximum Mean Discrepancy (MMD)** compare directement les deux distributions **entières** dans un espace de features :


$$\text{MMD}^2(P, Q) = \|\mu_P - \mu_Q\|_{\mathcal{H}}^2$$

C'est la distance entre les **moyennes des distributions** dans un espace de Hilbert $\mathcal{H}$ induit par un noyau k . Le modèle que nous avons implémenté s'inscrit dans cette famille. Il utilise la MMD comme métrique de comparaison entre distributions .

Rôle du noyau

Le noyau $k : \mathcal{X} \times \mathcal{X} \rightarrow \mathbb{R}$ est au cœur du système , il détermine la **géométrie** dans laquelle les distributions sont comparées, et donc la qualité du signal reçu par le générateur.

Architecture MMD-GAN



Pipeline

- **Générateur** G_ψ : transforme un bruit $z \sim \mathcal{N}(0, I)$ en image fausse , minimise la MMD
- **Critique** h_θ : projette images réelles et fausses dans un espace de features , maximise la MMD
- **Noyau** k : calcule la MMD entre les features réelles et fausses


$$\text{MMD}(\mathbb{P}, \mathbb{Q}; \mathcal{H}) = \sup_{f \in \mathcal{H}, \|f\|_{\mathcal{H}} \leq 1} \mathbb{E}_{\mathbb{P}} f(X) - \mathbb{E}_{\mathbb{Q}} f(Y)$$

$$f^*(x) \propto \mathbb{E}_{\mathbb{P}} k(X, x) - \mathbb{E}_{\mathbb{Q}} k(Y, x)$$

Bande passante du noyau — Données synthétiques 2D


$$k(x, y) = e^{\frac{-\|x-y\|^2}{2\sigma^2}}$$

$$f^*(x) \propto \mathbb{E}_{\mathbb{P}} k(X, x) - \mathbb{E}_{\mathbb{Q}} k(Y, x)$$




$\sigma = 2$

$\nabla_x k$ non nul partout
mais $\|\nabla_x k\| \ll 1$.



$\sigma = 0.1$



$\sigma = 0.05$

Fort $\nabla_x k$ autour des
données d'origine mais
très-local.

Pouvoir discriminant vs. Étendue spatiale


Proposition (Compromis bande passante–discriminabilité)

Pour des noyaux de la forme
 $k(x, y) = f(\|x - y\|^2)$, $f(0) = 1$
on définit la **bande passante- d**
comme


$\sigma_d = \sup\{x \mid f'(x) < -d\}$. Alors
:

$$\sigma_d \cdot d \leq 1$$

*Il est impossible d'avoir
simultanément un gradient à la
fois fort et spatialement étendu.*



$\sigma = 2$: diffus, $\|\nabla k\|$ faible




$\sigma = 0.1$: bon compromis




$\sigma = 0.05$: fort mais hyper-local

Visualiser la dérivée en 1D


$$f(t) = e^{\frac{-t^2}{2\sigma^2}}$$



$\sigma = 2$



$\sigma = 0.1$



$\sigma = 0.05$

Suivi des hyperparamètres — ACP 3D, moyenner des Noyaux

Visualisation PCA 3D


Nous projetons les features sur les **3 composantes principales** de la matrice de covariance associée à la matrice de données jointe $X = \begin{bmatrix} \text{features réelles} \\ \text{features générées} \end{bmatrix}$

Choix de la bande passante


Nous pouvons utiliser un noyau *mélange* qui combine plusieurs échelles :

$$k(x, y) = \sum_{k=1}^K k_{\sigma_k}(x, y).$$

Critique en avance sur le générateur



Les features générées se rapprochent de celles réelles



Gradient penalty et activation penalty

- **Gradient Penalty:** La GP contraint la pente de la fonction f à rester proche de 1 entre les images réelles et générées, empêchant le critique d'exploiter des gradients arbitrairement raides qui rendraient le signal inutilisable pour le générateur.
- **Activation Penalty :** La pénalité d'activation borne directement la norme des features produites par le critique, l'empêchant d'augmenter mécaniquement la MMD en amplifiant simplement l'échelle de ses sorties plutôt qu'en apprenant une représentation discriminante.

Commentaires sur les expériences sur MNIST

- **Noyau RBF($\sigma = 1$)** : Chiffres très nets et reconnaissables, MMD^2 descend de 0.98 à 0.21 : un signal exploitable toujours. Le modèle est **stable**. Pas de saturation du RBF à cette échelle.
- **RBF avec Gradient Penalty** : Dégradation forte. Le GP force des features à faible échelle, ce qui sature le noyau RBF et casse le gradient (le log d'act montent à 1455).
- **rbf_gp_act** La meilleur résultat entre les 3. Les logs sont stables.



Figure : Échantillons générés avec le noyau RBF et ses variantes.

Commentaires sur les expériences sur MNIST

- **Noyau RQ** : Chiffres nets, Mais MMD^2 diverge complètement.
- **RQ avec Gradient Penalty** : La GP seule **ne suffit pas à borner les features avec le noyau RQ**, act grimpe à 130 206 en fin d'entraînement
- **RQ_gp_act** Chiffres nets et bien formés, Logs bornés , MMD^2 finale 0.58 (convergence active, pas de saturation).



Figure : Échantillons générés avec le noyau RQ et ses variantes.

Commentaires sur les expériences sur MNIST

- **learn_plain** : Résultats bons. Les α convergent vers 0.05
autorégularisation implicite.
- **learn_gp** : Moins de qualité. Act grimpe à 49 058.
- **learn_gp_act** Excellent, parmi les meilleurs de toute la grille, Les logs sont stables, et les α convergent.




Figure : Échantillons générés avec le noyau appris et ses variantes.


CelebA — Le noyau RBF sature

Constat

- **Sans régularisation** : la MMD s'écrase sur le plafond dès l'itération $\sim 6000 \rightarrow$ taches de couleur, pas de structure de visage.
- **GP seule** : ne règle rien, la saturation persiste et la GP finit par s'emballer.
- **GP + activation penalty** : stabilise l'entraînement, mais visages flous et peu diversifiés.



rbf_plain – aucune structure



rbf_gp_act – stable mais flou

Pourquoi?

$\sigma = 1$ fixe $\Rightarrow$ portée trop étroite pour la dimensionnalité de CelebA (64×64 couleur) $\Rightarrow$ pénalise la diversité visuelle.

CelebA — RQ^* fixe vs. RQ^* appris

RQ^* fixe (exp. 4–6)


Même classement que sur MNIST :

- exp. 4 (sans GP) : instable
- exp. 5 (GP seule) : partielle
- **exp. 6 (GP + act)** : la plus stable et diversifiée


Décroissance polynomiale $\Rightarrow$ pas de saturation même à grande échelle de features.

RQ^* appris (exp. 7–9)


- Sans régularisation : fortement instable.
- GP seule : améliore mais **dégrade en fin d'entraînement.**
- **GP + act** : comportement le plus robuste, limite la dérive des α .



RQ^* instable



RQ^* GP+act



appris GP+act

CelebA — Ce qu'on en retient

Effet de la dimensionnalité

L'explosion du gradient penalty sans régularisation est **bien plus sévère sur CelebA que sur MNIST** : confirme que l'instabilité s'aggrave avec la dimension des données.

Évolution des bandwidths α


- Sans GP : les α se contractent.
- GP seule : dérive vers le haut, en phase avec les sursauts de GP.
- **Activation penalty : contient cette dérive.**

Conclusion

GP + activation penalty reste la configuration la plus robuste sur CelebA comme sur MNIST. Le noyau RQ* (fixe ou appris) domine largement le RBF dès que la dimension augmente.

Restauration profonde en utilisant un MMD-GAN préentraîné

Choix de $z \in Z$
(convenable) avec $\|z\|$ faible
puis Forward pass dans G_θ



Exploitation du prior appris par le générateur G_θ

Supposons que l'image qu'on souhaite restaurer appartient à une distribution de probabilité apprise par le générateur G_θ d'un MMD GAN. On peut exploiter ce prior en l'encodant dans R

Restauration par méthodes variationnelles

On propose de résoudre un problème de restauration en minimisant une énergie du type :


$$\hat{x} \in \arg \min_x E(x) = f(y, x) + \lambda R(x)$$

Implémentation

On cherche une image proche de y mais qui reste une sortie probable de G_θ
La formulation de la restauration devient
$$\hat{z} \in \arg \min_z f(y, G_\theta(z)) + \frac{\lambda}{2} \|z\|^2,$$
$$\hat{x} = G_\theta(\hat{z}).$$

Débruitage sur Mnist (Bruit additif gaussien)


Débruitage de digits Mnist (Descente de gradient sur $E(y)$)



Conditionner le générateur en encodant des classes dans l'espace latent Z


On suppose qu'on dispose d'un générateur de MMD GAN préentraîné

Encoder une classe dans Z




Conditionner le générateur en encodant des classes dans l'espace latent Z

Génération conditionnée sur Mnist après encodage dans Z



Interpolation dans Z



References I



I. Goodfellow et al. *Generative Adversarial Nets*. NeurIPS 2014. arXiv:1406.2661.



M. Bińkowski, D. J. Sutherland, M. Arbel, A. Gretton. *Demystifying MMD GANs*. ICLR 2018. arXiv:1706.08500.



M. Arjovsky, S. Chintala, L. Bottou. *Wasserstein Generative Adversarial Networks*. ICML 2017.



I. Gulrajani, F. Ahmed, M. Arjovsky, V. Dumoulin, A. Courville. *Improved Training of Wasserstein GANs*. NeurIPS 2017.



A. Gretton, K. Borgwardt, M. Rasch, B. Schölkopf, A. Smola. *A Kernel Two-Sample Test*. JMLR 13, 2012.



A. Müller. *Integral Probability Metrics and Their Generating Classes of Functions*. Advances in Applied Probability 29(2), 1997.

Noyaux utilisés

Noyau RBF (Gaussien)

- Décroissance **exponentielle** — sature rapidement quand $\|x - y\| \gg \sigma$.
- Un seul paramètre d'échelle σ , fixé à 1 dans nos expériences.

$$k_{\sigma}^{\text{rbf}}(x, y) = \exp\left(-\frac{\|x - y\|^2}{2\sigma^2}\right)$$

Noyau RQ* (Rationnel Quadratique + linéaire)

- Décroissance **polynomiale** — robuste à la saturation même à grande distance.
- Mélange sur plusieurs échelles $\alpha \in \{0.2, 0.5, 1, 2, 5\}$ + terme linéaire.
- Dans la variante **apprise**, les α_i sont optimisés conjointement avec le critique.

$$k^{\text{rq}^*}(x, y) = \sum_{\alpha \in \mathcal{A}} \left(1 + \frac{\|x - y\|^2}{2\alpha}\right)^{-\alpha} + \langle x, y \rangle$$